



# Optimizing Korean Tech RAG Performance via HTML-Aware Hierarchical Chunking and Hybrid Search

Do-Il Choi, Young-Jung Suh  
School of Computer Science and Engineering National University  
dohana1205@gmail.com, youngjung.suh@kongju.ac.kr

## BACKGROUND

### 블로그의 지식 자산화와 AI 도입, GEO 검색 패러다임의 변화

- 기술 블로그의 지식 자산화**  
IT 기업 및 개발자 그룹의 전문성 홍보와 브랜드 가치 제고를 위한 핵심 지식 자산 구축 효과.
- AI 기반 챗봇 도입 가치**  
지식 정보 접근성을 극대화하고 사용자 이탈률을 감소시켜 서비스 전반의 경쟁력을 강화.
- GEO 기반 검색 패러다임 변화**  
전통적 검색(SEO)에서 AI 생성형 답변 엔진으로 생태계가 이동함에 따라 자사 콘텐츠의 인용률 최적화(GEO) 가치 급부상.

# +4,700%

AI 엔진 기반 유입 트래픽 성장률 (YoY)  
\*Adobe Digital Insights 데이터 기준. 생성 답변의 출처 링크 클릭이 자체 웹 생태계의 새로운 핵심 유입원으로 안착했음을 완벽히 방증.

#### 왜 지금 GEO에 주목해야 하는가?

- 사용자가 검색 결과 목록을 일일이 클릭하던 기존 방식에서, AI의 단일 요약 답변을 곧바로 신뢰하는 구조로 패러다임이 이동했습니다.
- 기술 문서의 구조적 무결성을 선제적으로 보존하여, AI 에이전트가 오인 없이 올바르게 인용하도록 유도하는 것이 핵심 열쇠입니다.

| CONCEPT DEFINITION                                                    |                            |                                           |
|-----------------------------------------------------------------------|----------------------------|-------------------------------------------|
| GEO의 직관적 정의                                                           |                            |                                           |
| 사용자가 AI 기반 검색 엔진에 질문했을 때, 답변 블록 내에 자사의 지식 콘텐츠가 채택되도록 조율하는 기술입니다.      | 키워드 매칭, 백링크, 메타 태그 정보 반영   | AI 기반 생성형 답변 엔진 최적화 (ChatGPT, Perplexity) |
|                                                                       |                            | AI 모델의 답변 채택 및 정확한 출처 인용(Citation)        |
| 신뢰도 높은 고품질 정밀 정보를 제공함으로써, 정확한 출처 인용(Citation) 링크를 선정하는 차세대 최적화 기술입니다. | 검색 로봇 크롤링 위주의 단순 HTML 구조   | AI 에이전트 인식이 용이한 정제된 구조 데이터 (Markdown)     |
| 최종 목표                                                                 | 검색 결과 페이지(SERP) 1페이지 상위 노출 | AI 생성 답변 내 핵심 정보 포함 및 출처 링크 획득            |

## PROPOSED METHOD

### 기존 연구의 한계점 및 연구 동기

| CONVENTIONAL LIMIT                                                                                                                                                                                                                                                         | RESEARCH OBJECTIVE                                                                                                                                                                                                                                                         |
|----------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|----------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|
| <b>기존 선행 연구의 한계점</b> <ul style="list-style-type: none"><li><b>영문 일반 웹 텍스트 중심 아키텍처</b><br/>HtmlRAG 등 최신 방법론들은 주로 영어권 일반 웹 레이아웃을 표준 기반으로 가공하여 최적화함.</li><li><b>한국어 도메인 적용 시 문맥 손실 한계</b><br/>구조적 밀도(코드 블록, 표)가 높은 한국어 기술 블로그 도메인에 적용 시 기계적 텍스트 분할로 인한 문맥 손실 한계 존재.</li></ul> | <b>연구 목적</b> <ul style="list-style-type: none"><li><b>도메인 고유 기술 구조 특성 반영</b><br/>한글 기술 문서 도메인이 지닌 소스코드(&lt;pre&gt;)와 정형 표(&lt;table&gt;) 스키마 구조의 특성을 밀착 반영.</li><li><b>마크업 구조 보존 아키텍처 구현</b><br/>정보 단절 현상을 완전 차단하고 논리 무결성을 유지하는 마크업 구조 보존형 RAG 전처리 아키텍처 설계 및 구현.</li></ul> |

### 구조 보존형 RAG 파이프라인 아키텍처

| STAGE 01                                                                                                                   | STAGE 02                                                                                                              | STAGE 03                                                                                                             |
|----------------------------------------------------------------------------------------------------------------------------|-----------------------------------------------------------------------------------------------------------------------|----------------------------------------------------------------------------------------------------------------------|
| <b>소스코드 · 표 격리</b> <ul style="list-style-type: none"><li>BeautifulSoup 활용 구문 선제 분리</li><li>분할 시 발생하는 구조 훼손 원천 방지</li></ul> | <b>헤더 기반 계층 청킹</b> <ul style="list-style-type: none"><li>H1~H4 구조 기반 세부 청크 분할</li><li>각 청크 내 상위 경로 메타데이터 주입</li></ul> | <b>하이브리드 재정렬</b> <ul style="list-style-type: none"><li>키워드 및 의미 가중 스코어 결합</li><li>Cross-Encoder 활용 컨텍스트 정제</li></ul> |

#### 1. 실시간 사용자 질의 및 추론 파이프라인 (INFERENCE PIPELINE)



#### 2. 자동 게시글 추가 및 색인 파이프라인 (INGESTION PIPELINE)



| 질의 출처             |    | 질의 유형           |    |
|-------------------|----|-----------------|----|
| 항목                | n  | 유형              | n  |
| 블로그 댓글·Q&A        | 6  | Code-related    | 10 |
| 기타 Q&A (실사용자 질의)  | 4  | Explanation     | 7  |
| Gemini 3.0 Pro 합성 | 10 | Configuration   | 1  |
| 합계                | 20 | Troubleshooting | 2  |
| 합계                |    | 합계              | 20 |

## EXPERIMENTS

### Ragas Evaluation Framework

RAG 시스템의 생성 성능을 다각도로 검증하기 위한 핵심 지표

#### GENERATION

##### I Faithfulness

생성된 답변이 주어진 컨텍스트의 사실에 얼마나 부합하는가 (환각 검증)

##### II Answer Relevancy

생성된 답변이 사용자의 질문 취지에 얼마나 직접적으로 부합하는가

### Faithfulness

주어진 컨텍스트(Context)를 바탕으로 생성된 답변(Answer)이 얼마나 사실에 기반하고 있는지를 측정합니다. 이는 시스템이 지식을 위조(Hallucination)하지 않도록 관리하는 핵심 지표입니다.

$$\text{Faithfulness} = \frac{\text{문맥에서 추론 가능한 진술(Statement) 수}}{\text{답변 내 전체 진술 수}}$$

### Answer Relevancy

생성된 답변이 사용자의 원래 질문에 얼마나 적절하고 명확하게 응답하고 있는지를 측정합니다. 정보의 정확성보다는 '질문의도 부합 여부'에 집중하여 평가를 수행합니다.

$$S = \frac{1}{n} \sum_{i=1}^n \text{sim}(q, q_i)$$

(원본 질문 q와 답변을 통해 역생성한 질문 q\_i 간의 코사인 유사도)

### Retrieval 방식 RAGAS 비교 평가

Dense 단독 대비 BM25 및 Cross-Encoder 결합 파이프라인 정량 성능 비교

| Answer Relevancy (질의 연관성) 비교  | 평가 알고리즘 스택 조합              | Faithfulness (충실성) | Answer Relevancy (연관성) |
|-------------------------------|----------------------------|--------------------|------------------------|
| 0.749<br>Dense                | Dense Retrieval (단독 기본형)   | 0.746              | 0.749                  |
| 0.796<br>Hybrid               | Hybrid Retrieval (가중 융합형)  | 0.777              | 0.796                  |
| 0.848<br>Hybrid Reranker (제안) | Hybrid Reranker (본 연구 제안형) | 0.794              | 0.848                  |

지표 정량 분석: BM25와 Dense 스코어 가중 융합 후 Cross-Encoder Reranker를 거치는 제안 파이프라인이, 단순 Dense 단독 방식 대비 질의 연관성(Answer Relevancy) 지표에서 13.2%의 명확한 성능 향상을 입증했습니다.

### LLM 모델별 성능 비교 평가

정제된 HTML 청킹 기반의 답변 생성 모델 비교 및 아키텍처 실효성 검증

| 최종 생성부 타겟 언어모델 스택                 | 파라미터 계층 스케일            | Faithfulness (데이터 충실성) | Answer Relevancy (질의 연관성) |
|-----------------------------------|------------------------|------------------------|---------------------------|
| EXAONE-4.0-1.2B (본 최적화 파이프라인 결합형) | 1.2B (경량 오픈소스)         | 0.801                  | 0.874                     |
| GPT-4o-mini (Vanilla 순정형 스택)      | Commercial Mid Scale   | 0.802                  | 0.877                     |
| GPT-4o (Vanilla 대형 모델 인터페이스)      | Commercial Large Scale | 0.812                  | 0.879                     |

학술적 시사점: 1.2B 초경량 오픈소스 모델에 본 최적화 파이프라인을 결합하면, 수백 배 더 큰 상용 거대 모델(GPT-4o) 제품군과 통계적으로 대등한 수준의 생성 품질을 달성하여 인프라 비용을 혁신적으로 절감할 수 있습니다.

## CONCLUSION

### Limitations & Future Tasks

RAG 시스템의 실효성 검증과 차세대 서빙 인프라 구축을 위한 보완 과제

|                                                                                                                               |                                                                                                                            |
|-------------------------------------------------------------------------------------------------------------------------------|----------------------------------------------------------------------------------------------------------------------------|
| <b>LIMITATION 01</b><br><b>벤치마크 데이터셋의 규모 제약</b><br>소규모 파일럿 데이터셋: 단 20종의 질의셋 기반 검증으로 실제 운영 환경의 다채로운 질의 패턴을 포괄하기 어렵습니다.         | <b>LIMITATION 02</b><br><b>정량 지표 중심 평가의 한계</b><br>주관적 유용성 대비 미비: 정량적 수치 계산에만 치중되어 있어, 실제 사용자가 느끼는 정성적 만족도 검증이 미비합니다.       |
| <b>FUTURE TASK 01</b><br><b>실서비스 배포 및 실효성 검증</b><br>인간 평가 지표(Human Eval) 확보: 실제 프로덕션 트래픽 연동과 정성적 피드백 수집을 바탕으로 실효성을 검증할 계획입니다. | <b>FUTURE TASK 02</b><br><b>마크다운 동적 서빙 인프라 구축</b><br>AI 에이전트 맞춤형 인프라: 외부 검색 크롤러 감지 시, 무거운 HTML 대신 정제된 고순도 마크다운을 실시간 서빙합니다. |
| <b>운영 전략:</b> 실서비스 로그(User Query & Log Data) 기반의 정기적 평가를 통해 Context Precision 및 Recall의 정합성을 지속적으로 검증하고 검색 품질을 고도화합니다.        |                                                                                                                            |